

Mariano Antonio Vunge
Thallia Aline Ramos

SPRINT 1 AGRO M₂

Londrina

2025

Sumário

Sumário	2
1 INTRODUÇÃO	3
1.1 Objetivo	4
2 APLICAÇÕES DE TÉCNICAS DE CLASSIFICAÇÃO (SCORING E AGRUPAMENTO)	5
2.1 Processo Analítico Hierárquico (AHP)	5
2.2 TOPSIS (Similarity to Ideal Solution)	5
2.3 Aplicações de Técnicas de Classificação	6
2.4 Agrupamento (Clustering) para Segmentação de Risco (K-Means)	6
2.5 Validação e Preparação dos Dados	7
2.6 Coleta e Fontes de Dados	7
2.7 Engenharia e Qualidade de Dados	8
3 REVISÃO DA LITERATURA E METODOLOGIA	10
4 DADOS E ANÁLISE EXPLORATÓRIA	12
4.1 Estrutura do Conjunto de Dados	12
4.2 Análise Exploratória de Dados (EDA)	12
4.3 Gráficos	13
4.4 Estrutura do Projeto no VS Code	17
4.5 Análise AHP	18
4.6 Análise TOPSIS	19
5 RESULTADOS ALCANÇADOS	22
6 CONCLUSÕES	23
Referências	24

1 Introdução

A priorização eficaz de projetos, tarefas ou alternativas de negócio, especialmente em contextos dinâmicos como um *Sprint* de desenvolvimento ágil, exige um mecanismo de decisão que seja ao mesmo tempo transparente, lógico e capaz de ponderar múltiplos fatores. A subjetividade inerente aos julgamentos de valor representa um risco à consistência e à otimização da alocação de recursos.

Neste relatório do **Sprint 1** da iniciativa **AGRO M2**, apresenta-se o desenvolvimento e a aplicação do conceito de **Score Bidimensional**, uma ferramenta robusta de apoio à decisão multicritério (MCDM - *Multi-Criteria Decision Making*). Este score visa mapear e ordenar alternativas sob duas dimensões cruciais, como, por exemplo, "Risco vs. Impacto" ou "Custo vs. Benefício", garantindo que as decisões de prioridade sejam tomadas com base em um racional *multicritério* e não em julgamentos puramente intuitivos ou univariados.

Para conferir o necessário rigor analítico a este processo, o Score Bidimensional é estruturado através da hibridização de duas das mais consagradas técnicas de MCDM: o **Analytic Hierarchy Process (AHP)** e a **Technique for Order Preference by Similarity to Ideal Solution (TOPSIS)**.

- O **AHP**, desenvolvido por Thomas Saaty, é empregado na fase de estruturação hierárquica e na derivação dos *pesos* relativos de importância para cada critério. Através de comparações pareadas e do cálculo da Razão de Consistência ($RC \leq 0,10$), o AHP assegura que os julgamentos de valor da equipe de decisão sejam internamente lógicos e consistentes [1].
- O **TOPSIS**, proposto por Hwang e Yoon, é então aplicado para realizar a ordenação final das alternativas. Utilizando os pesos derivados do AHP, o TOPSIS classifica as alternativas com base na sua similaridade relativa à Solução Ideal Positiva (SIP) e na distância à Solução Ideal Negativa (SIN) [2].

A sinergia entre AHP e TOPSIS resulta em uma metodologia que não apenas define prioridades (AHP), mas também ordena as alternativas de forma quantitativa e clara (TOPSIS), materializando o Score Bidimensional como um poderoso catalisador para a tomada de decisão estratégica no contexto do AGRO M2. O presente documento detalha o framework, os resultados e as implicações desta metodologia para a priorização de itens na *backlog* do Sprint.

1.1 Objetivo

O objetivo geral do projeto é desenvolver um Score de Confiabilidade do Produtor, utilizando a análise de dados e técnicas de Decisão Multicritério para criar uma pontuação que seja útil tanto para o produtor agrícola (vendedor) quanto para as indústrias e cooperativas (compradoras).

Este score serve para:

- Para o Produtor (Vendedor): Ter uma pontuação objetiva que comprove sua confiabilidade e desempenho, facilitando a negociação de contratos e o acesso a melhores condições de mercado com as cooperativas e indústrias.
- Para Indústrias e Cooperativas (Compradoras): Obter uma métrica confiável e transparente para avaliar o risco e o potencial de cada produtor. Isso permite otimizar a gestão da cadeia de suprimentos, priorizar parcerias estratégicas e tomar decisões de compra mais seguras e informadas.

Em resumo, o projeto busca criar uma ferramenta analítica que torne o relacionamento comercial entre o produtor e a indústria mais transparente e eficiente, baseando-se em dados e em um rigoroso processo de pontuação multicritério.

2 Aplicações de Técnicas de Classificação (Scoring e Agrupamento)

A consolidação do Score Bidimensional e a categorização dos produtores foram alcançadas mediante a aplicação de técnicas de classificação e agrupamento de dados, transformando métricas brutas em indicadores estratégicos de confiabilidade.

O método TOPSIS foi o núcleo da geração do Score de Confiabilidade do Produtor, pois sua função é ordenar as alternativas (os produtores) com base na sua performance multicritério.

2.1 Processo Analítico Hierárquico (AHP)

O AHP é utilizado para estruturar o problema hierarquicamente e determinar o peso (prioridade) de cada critério [1].

- **Estruturação e Julgamentos:** A técnica baseia-se em Comparações Pareadas, onde os decisores utilizam a **Escala de Saaty** (9 pontos) para quantificar o julgamento de importância relativa entre os critérios.
- **Cálculo da Consistência:** Para garantir que os julgamentos sejam lógicos e não aleatórios, é calculada a **Razão de Consistência (RC)**. A regra fundamental exige que a RC seja menor ou igual a 0,10 ($RC \leq 0,10$).

2.2 TOPSIS (Similarity to Ideal Solution)

O TOPSIS é o método de classificação que utiliza os pesos gerados pelo AHP para ordenar as alternativas. O princípio fundamental do TOPSIS é que a melhor alternativa é aquela que está: [2]

- Mais próxima da **Solução Ideal Positiva (SIP)**: a solução hipotética que representa o melhor valor possível para todos os critérios.
- Mais distante da **Solução Ideal Negativa (SIN)**: a solução hipotética que representa o pior valor possível para todos os critérios.

2.3 Aplicações de Técnicas de Classificação

A consolidação do Score Bidimensional e a categorização dos produtores foram alcançadas mediante a aplicação de técnicas de classificação e agrupamento de dados, transformando métricas brutas em indicadores estratégicos de confiabilidade.

O TOPSIS foi o núcleo da geração do Score de Confiabilidade do Produtor, ordenando as alternativas com base na sua performance multicritério, conforme a metodologia detalhada na Seção.

- **Ponderação:** A Matriz de Decisão é ponderada pelos pesos de critérios derivados do AHP, garantindo que a relevância atribuída pelos decisores seja incorporada ao cálculo.
- **Geração do Score:** O resultado final do TOPSIS é o **Coefficiente de Similidade Relativa (C_i^*)** para cada produtor. Este coeficiente é normalizado (o a 100) e representa o quão aderente a performance do produtor está à Solução Ideal Positiva (SIP) em relação à Solução Ideal Negativa (SIN).
- **Valor Estratégico:** Um C_i^* alto sinaliza um produtor de alta confiabilidade e baixo risco, enquanto um C_i^* baixo indica a necessidade de maior cautela nas operações de compra e concessão de crédito.

2.4 Agrupamento (Clustering) para Segmentação de Risco (K-Means)

Complementarmente à classificação individual, utilizou-se a técnica de aprendizado de máquina não supervisionado **K-Means** para segmentar os produtores em grupos com características e riscos semelhantes [3].

- **Objetivo:** Identificar perfis de risco e performance homogêneos dentro do dataset para a formulação de estratégias de mercado e mitigação de risco das compradoras [4].
- **Definição do k:** O número ótimo de clusters ($k = 4$ na Sprint 1) foi determinado heurísticamente utilizando o **Método do Cotovelo** (*Elbow Method*).
- **Visualização e Análise:** Os produtores foram categorizados em quatro clusters distintos. A visualização desta segmentação foi realizada com a

Análise de Componentes Principais (PCA), permitindo que os gestores identifiquem claramente os grupos (ex: Alto Risco, Média Produtividade, etc.) e adaptem suas abordagens para cada segmento.

O uso combinado de TOPSIS e K-Means forneceu uma abordagem bidimensional pa

2.5 Validação e Preparação dos Dados

O sucesso do Score Bidimensional depende diretamente da qualidade, completude e relevância dos dados de entrada. Nesta etapa, foi realizada a coleta, validação e enriquecimento do conjunto de dados para garantir a robustez dos modelos AHP-TOPSIS e K-Means.

2.6 Coleta e Fontes de Dados

O conjunto de dados inicial foi criado a partir de uma base fornecida pelo cliente, contendo informações primárias sobre o desempenho dos produtores (vendedores) e as necessidades das indústrias/cooperativas (compradoras). Para complementar e enriquecer esta base, foi utilizado um conjunto de dados secundário focado no *Rendimento das Culturas Agrícolas (Crop Yield)* como *baseline* de produtividade e variáveis ambientais [4].

Os dados utilizados abrangeram:

- **Indicadores Agrícolas:** Produtividade, tipos de culturas, uso de pesticidas e fatores climáticos (temperatura, precipitação).
- **Indicadores Financeiros (Normalizados):** Limite de crédito, níveis de endividamento e histórico de pagamentos, essenciais para a dimensão de "Risco" do score.

Reconhecendo as limitações inerentes aos dados primários (falhas, inconsistências e baixo volume inicial), a fase de preparação foi aprimorada com o suporte de ferramentas de Inteligência Artificial (*Large Language Models* - LLMs), seguindo metodologias avançadas de engenharia de dados [5, 6].

Este processo de enriquecimento envolveu:

- **Geração Sintética de Registros:** Criação de registros financeiros e de cultivo simulados para aumentar a diversidade e o volume do *dataset* (*data*

augmentation). Isso foi crucial para treinar o modelo K-Means de forma mais estável, evitando o superajuste a um conjunto de dados pequeno.

- **Normalização e Padronização:** Aplicação de algoritmos para garantir que as variáveis de diferentes magnitudes (ex: rendimento em toneladas vs. limite de crédito em reais) fossem comparáveis e não enviesassem os resultados do TOPSIS.
- **Tratamento de Inconsistências:** Identificação e correção de preenchimento de dados faltantes (imputação) de forma estatisticamente plausível, elevando a **Taxa de Completude** do *dataset* para 98.5%.

2.7 Engenharia e Qualidade de Dados

O sucesso do Score Bidimensional depende diretamente da qualidade, completude e relevância dos dados de entrada. Nesta etapa, foi realizada a coleta, validação e enriquecimento do conjunto de dados para garantir a robustez dos modelos AHP-TOPSIS e K-Means [7]. O processo de engenharia concentrou-se em estabelecer um *pipeline* de processamento que não apenas estruturasse os dados, mas também garantisse sua alta qualidade, vital para a validade do Score Bidimensional.

O conjunto de dados inicial foi criado a partir de uma base fornecida pelo cliente, contendo informações primárias sobre o desempenho dos produtores (vendedores) e as necessidades das indústrias/cooperativas (compradoras). Para complementar e enriquecer esta base, foi utilizado um conjunto de dados secundário focado no *Rendimento das Culturas Agrícolas (Crop Yield)* como *baseline* de produtividade e variáveis ambientais [4].

Os dados utilizados abrangeram:

- **Indicadores Agrícolas:** Produtividade, tipos de culturas, uso de pesticidas e fatores climáticos (temperatura, precipitação).
- **Indicadores Financeiros (Normalizados):** Limite de crédito, níveis de endividamento e histórico de pagamentos, essenciais para a dimensão de "Risco" do score.

Reconhecendo as limitações inerentes aos dados primários (falhas, inconsistências e baixo volume inicial), a fase de preparação foi aprimorada com o suporte de ferramentas de Inteligência Artificial (*Large Language Models* -

LLMs), seguindo metodologias de engenharia de dados para *data augmentation* e tratamento de dados faltantes [8].

Este processo de enriquecimento envolveu:

- **Geração Sintética de Registros:** Criação de registros financeiros e de cultivo simulados para aumentar a diversidade e o volume do *dataset*. Isso foi crucial para treinar o modelo K-Means de forma mais estável, evitando o superajuste a um conjunto de dados pequeno.
- **Normalização e Padronização:** Aplicação de algoritmos para garantir que as variáveis de diferentes magnitudes (ex: rendimento em toneladas vs. limite de crédito em reais) fossem comparáveis e não enviesassem os resultados do TOPSIS.
- **Tratamento de Inconsistências:** Identificação e correção de *outliers* e preenchimento de dados faltantes (imputação) de forma estatisticamente plausível, elevando a **Taxa de Completude** do *dataset* para **98.5%**.

3 Revisão da Literatura e Metodologia

O desenvolvimento do Score Bidimensional e a análise multicritério foram fundamentados em conceitos e metodologias robustas, amplamente discutidas na literatura de pesquisa operacional, inteligência de negócios e apoio à decisão. A presente seção consolida os principais arcabouços teóricos e descreve a metodologia aplicada no *Sprint 1*.

A tomada de decisão em ambientes complexos, caracterizada pela presença de múltiplos objetivos e critérios frequentemente conflitantes, demanda o uso de métodos estruturados. O campo do *Multi-Criteria Decision Making* (MCDM) surge como uma área de estudo dedicada a auxiliar na escolha da melhor alternativa de um conjunto finito de opções [1, 2]. Dois dos métodos mais proeminentes nesse campo, o Processo Analítico Hierárquico (AHP) e a Técnica para Preferência de Ordem por Similaridade à Solução Ideal (TOPSIS), foram adotados neste projeto.

- **Analytic Hierarchy Process (AHP):** Desenvolvido por Thomas L. Saaty na década de 1970, o AHP é uma técnica que decompõe problemas complexos em uma estrutura hierárquica para derivar pesos de prioridade para os critérios. Sua principal característica é a utilização de comparações pareadas, que quantificam o julgamento dos decisores sobre a importância relativa de cada critério. A coerência destes julgamentos é matematicamente validada através da Razão de Consistência (RC), garantindo um processo lógico e transparente [1].
- **Technique for Order Preference by Similarity to Ideal Solution (TOPSIS):** O TOPSIS, introduzido por Hwang e Yoon, é um método de classificação que ordena as alternativas com base em suas distâncias a uma Solução Ideal Positiva (SIP) e a uma Solução Ideal Negativa (SIN). A melhor alternativa é aquela que se aproxima mais da SIP e se afasta mais da SIN. Esta abordagem é particularmente eficaz para problemas de classificação onde o objetivo é ranquear um conjunto de alternativas em ordem de preferência [2].
- **Modelos Híbridos:** A combinação de AHP e TOPSIS é amplamente utilizada para superar as limitações de cada método individualmente. O AHP é ideal para a determinação dos pesos dos critérios, que é a

parte mais subjetiva do problema. O TOPSIS, por sua vez, utiliza esses pesos objetivos para classificar as alternativas de forma matemática e rigorosa. A sinergia dos dois métodos resulta em um modelo híbrido robusto, que combina a capacidade de ponderação subjetiva do AHP com a objetividade de classificação do TOPSIS [9].

- **Agrupamento de Dados (Clustering):** A análise de dados também se beneficia de técnicas de agrupamento não supervisionadas, como o K-Means [3]. Este algoritmo é usado para segmentar automaticamente um conjunto de dados em subgrupos (clusters) homogêneos, onde cada cluster é internamente similar e externamente dissimilar dos demais. No contexto deste projeto, o K-Means foi empregado para segmentar os produtores em perfis de risco e performance, complementando a classificação individual do TOPSIS.

A metodologia deste *Sprint* seguiu uma abordagem estruturada para a criação do Score Bidimensional, integrando as etapas de engenharia de dados, modelagem multicritério e visualização. O processo, foi executado em três fases principais:

1. **Validação e Preparação dos Dados:** Nesta fase, o *dataset* foi criado, validado, normalizado e enriquecido com dados sintéticos. Foram realizadas análises de completude, consistência e tratamento de *outliers* para garantir a alta qualidade dos dados de entrada.
2. **Modelagem Híbrida AHP-TOPSIS:**
 - **AHP:** Os critérios de avaliação (ex: Produtividade, Consistência Financeira) foram hierarquizados e os seus pesos relativos foram determinados através de comparações pareadas, garantindo que os julgamentos de importância fossem consistentes ($RC \leq 0,10$).
 - **TOPSIS:** Utilizando os pesos do AHP, as alternativas (os produtores) foram classificadas com base na sua similaridade com a solução ideal, gerando um score numérico final (0 a 100).
3. **Análise e Visualização:** Os scores gerados foram validados através de técnicas de agrupamento. O método K-Means foi aplicado para segmentar os produtores em grupos de risco/performance, e os resultados foram visualizados em um *dashboard* interativo em Streamlit, facilitando a interpretação e a tomada de decisão pelos *stakeholders*.

4 Dados e Análise Exploratória

A base de dados é o alicerce de qualquer modelo analítico. Para o desenvolvimento do Score Bidimensional, foi empregado um conjunto de dados composto por registros fornecidos pelo cliente e enriquecido por fontes externas de domínio público, como a base de dados de rendimento agrícola do Kaggle [4]. Esta seção detalha as características do conjunto de dados e as descobertas iniciais obtidas através da Análise Exploratória de Dados (EDA).

4.1 Estrutura do Conjunto de Dados

O conjunto de dados, preparado após as etapas de engenharia e tratamento de dados, registros financeiros e registros de cultivo, consolidando informações essenciais para a avaliação do produtor. Os registros representam uma observação e contêm variáveis cruciais, as quais foram categorizadas da seguinte forma:

- **Dados Agrícolas:** Incluem variáveis como tipo de cultura, área, temperatura média e precipitação. Esses dados são fundamentais para avaliar a produtividade e a consistência técnica do produtor.
- **Dados Financeiros:** Compreendem informações sobre o limite de crédito e o histórico de endividamento do produtor, servindo como indicadores-chave para a dimensão de "Risco" do Score Bidimensional.

A alta taxa de completude de **98.5%**, alcançada através de técnicas de imputação, garante que a maioria dos registros esteja apta para a análise, minimizando a perda de informações valiosas.

4.2 Análise Exploratória de Dados (EDA)

A EDA foi conduzida para obter uma compreensão profunda do comportamento dos dados, identificar padrões e detectar *outliers* antes da modelagem. As principais descobertas incluem:

- **Distribuição das Culturas:** A análise revelou uma distribuição variada das culturas, com gráficos de barras e de pizza mostrando a representatividade de cada tipo de cultivo no *dataset*.

- **Produtividade por Cultura:** Foram gerados gráficos de caixa (*boxplots*) que ilustram a produtividade média, a mediana e a dispersão dos dados para cada cultura, fornecendo *insights* sobre o desempenho médio do setor e identificando culturas com alta variabilidade de rendimento.
- **Correlação entre Variáveis:** Gráficos de dispersão (como a *Relação: Dívidas vs. Limite de Crédito*) foram utilizados para visualizar a correlação entre as variáveis financeiras, auxiliando na compreensão das relações de risco.

Os resultados da Análise Exploratória validaram a consistência dos dados e serviram de base para a seleção dos critérios que seriam ponderados no método AHP, bem como para a definição das alternativas a serem classificadas pelo TOPSIS. A base de dados foi construída com um conjunto de dados primário fornecido pelo cliente e enriquecido com dados secundários do portal Kaggle [4]. O aprimoramento do conjunto de dados original foi realizado através de técnicas avançadas de geração de dados sintéticos, elevando o volume de observações e garantindo a diversidade necessária para uma modelagem robusta.

4.3 Gráficos

O gráfico demonstra uma queda acentuada da Inércia à medida que k aumenta, até o ponto $k=4$. A partir de $k=4$, a redução percentual da Inércia torna-se significativamente menos pronunciada, configurando o "cotovelo" da curva. Portanto, o número ótimo de clusters foi determinado como $k=4$, conforme demarcado pela linha tracejada vertical vermelha. Este valor será utilizado na próxima fase de modelagem para garantir um agrupamento que maximiza a coesão interna dos grupos com a parcimônia no número de clusters.




Figura 1 – Método do cotovelo

O gráfico de dispersão na Figura 2 apresenta o resultado final do agrupamento (*clustering*). Para a visualização, os dados foram projetados nas duas primeiras **Componentes Principais (PCA)**, que retêm a maior parte da variância dos dados originais.




Figura 2 – Categoria de Score

O resultado da visualização e eficácia do algoritmo de agrupamento nas Figuras 3 e 4 . Observa-se que os clusters tendem a ocupar regiões geográficas distintas no espaço PCA, com fronteiras relativamente claras. Por exemplo, o cluster de cor vermelha (Cluster 1.0) se concentra predominantemente na região superior esquerda, enquanto o cluster azul-escuro (Cluster 0.0) domina a região inferior e o azul-claro (Cluster 3.0) a região inferior direita.



Figura 3 – Cluster PCS 2D




Figura 4 – Clusters PPCS 3D

A Figura 5 apresenta a distribuição quantitativa dos agricultores nas quatro categorias de *Score* de Confiabilidade (1: Baixa; 4: Alta), resultado da aplicação do modelo de *clustering*.

Resultados Chave: O gráfico evidencia que a maioria da carteira se encontra nas categorias intermediárias de risco:

Os extremos somam um número menor: **520** agricultores no *Score* 1 (Baixa Confiabilidade) e apenas **445** no *Score* 4 (Alta Confiabilidade).

Implicações Estratégicas: Esta distribuição direciona os esforços de gestão:

1. Foco na retenção e conversão dos grandes grupos (Scores 2 e 3).
2. Estratégias de mitigação de risco urgentes para o grupo *Score* 1.
3. Programas de fidelização e recompensa para o grupo *Score* 4.

O modelo permite, assim, a alocação eficiente de recursos baseada na criticidade e no volume de cada segmento.




Figura 5 – Distribuição agrícola

A Figura 6 ilustra a distribuição de culturas cultivadas pelos agricultores.

Análise: O gráfico de rosca demonstra uma **alta e equilibrada diversificação** entre as seis principais culturas. Todas as culturas (Barley, Rice, Wheat, Maize, Cotton e Soybean) representam entre **16,0% e 17,1%** da distribuição total, indicando que **não há uma cultura dominante** na base analisada.

Impacto Estratégico: Este equilíbrio implica que as estratégias de produtos e serviços devem ser desenhadas para atender à diversidade de culturas de forma uniforme, mitigando o risco de concentração e garantindo a relevância da oferta para a totalidade da carteira.




Figura 6 – Distribuição agrícola culturas

A Figura 7 consolida a análise da distribuição e da categorização final do Score de Confiabilidade da carteira.

1. Histograma (Esquerda): A distribuição contínua do Score (0 a 100) é ampla, com a **média** posicionada aproximadamente no centro da escala (demarcada pela linha tracejada). Esta dispersão demonstra a variabilidade do Score na base.

2. Gráfico de Barras (Direita): A categorização final divide a base em quatro grupos: Baixo Risco, Médio Risco, Confiável e Muito Confiável. Os grupos de **Médio Risco** e **Confiável** são os maiores em volume.




Figura 7 – Distribuição Scores Categorias

O objetivo é identificar o ponto ("cotovelo") onde o ganho na redução da Inércia se torna marginal. A curva mostra uma queda acentuada na Inércia até $k=4$. A partir deste ponto, a redução é menos significativa. O número ótimo de clusters foi determinado como $k=4$, conforme indicado pela linha tracejada e pela anotação "k ótimo = 4". Este valor confirma o número de quatro categorias (ou clusters) utilizado nas análises e visualizações anteriores do Score de Confiabilidade.




Figura 8 – Distribuição Scores

4.4 Estrutura do Projeto no VS Code

A Figura 9 ilustra a estrutura de arquivos e diretórios do projeto AGROM2-CODIGO, conforme visualizada no ambiente de desenvolvimento VS Code. Esta estrutura organiza todos os componentes necessários para a execução, modelagem e documentação do projeto de análise de dados.

- `.venv`: Pasta que contém o ambiente virtual Python. Garante que as dependências do projeto sejam isoladas e consistentes, evitando conflitos com outras instalações do sistema.
- `app.py`, `app1.py`, `app2.py`: Arquivos Python principais (`.py`), que provavelmente contêm o código de backend, lógica de processamento e as funções de modelo utilizadas (como os algoritmos de clustering).

- M2.ipynb: Um Jupyter Notebook que serve como um ambiente interativo para a experimentação, prototipagem, visualização dos dados (como os gráficos apresentados) e documentação das etapas de análise.
- requirements.txt: Arquivo crucial que lista todas as bibliotecas e pacotes Python necessários para que o projeto seja executado corretamente, garantindo a reprodutibilidade do ambiente virtual (.venv).
- Arquivos CSV (crop_yield.csv, pesticides.csv, tabela_resumo_10000_linhas.csv): Conjunto de dados agrícolas (datasets) utilizados no projeto. Eles contêm as informações originais sobre rendimento de culturas, uso de pesticidas e dados resumidos usados para treinamento e validação dos modelos.




Figura 9 – Estrutura VSCOD

4.5 Análise AHP

A figura 10 é um screenshot de uma interface de usuário, provavelmente desenvolvida em Streamlit (pela natureza da interface), que demonstra a configuração e o resultado da Análise com o Método AHP (Analytic Hierarchy Process).

O Método AHP é uma técnica de tomada de decisão multicritério que permite atribuir pesos e prioridades a diversos fatores (critérios) para calcular um score final.

A interface AHP valida a metodologia do Score, permitindo que stakeholders ajustem a importância relativa de diferentes critérios de negócio (por exemplo, priorizando o risco financeiro) e observem imediatamente o impacto nas estatísticas de distribuição do Score final.



Figura 10 – Técnica AHP

4.6 Análise TOPSIS

A Figura 11 exibe a interface de uma ferramenta de Análise com a Técnica TOPSIS, um método utilizado para ordenar alternativas (neste caso, os agricultores) com base na distância de uma solução ideal positiva e uma solução ideal negativa.

Esta seção permite definir a importância (pesos) de cada critério para o cálculo da pontuação, garantindo que a soma total seja 1,00.

- Os critérios, como Produtividade, Temperatura, Chuva, Crédito Limite, Dívidas e Risco Financeiro, são ponderados.
- A interface indica a necessidade de selecionar se o critério é benéfico (maior é melhor) ou não.
- Os pesos atribuídos influenciam diretamente o cálculo da pontuação TOPSIS.

O uso da técnica TOPSIS oferece uma metodologia alternativa e robusta ao AHP para gerar o Score de Confiabilidade. A ferramenta permite que os stakeholders avaliem o Score considerando a proximidade de cada agricultor a um perfil ideal de performance, fornecendo um Score preciso e ajustável.

A Figura 11 apresenta a aplicação da Técnica TOPSIS (*Technique for Order of Preference by Similarity to Ideal Solution*) para a pontuação da base.




Figura 11 – Técnica TOPSIS

A Figura 12 apresenta um resumo didático dos dois métodos de Análise Multicritério utilizados para o cálculo do Score de Crédito Rural: o AHP (Processo de Hierarquia Analítica) e o TOPSIS (Técnica para Ordem de Preferência por Similaridade à Solução Ideal).




Figura 12 – Análise multicriterios

A Figura 13 e 14 é um painel de comparação que demonstra as distribuições e os resultados dos Scores de Confiabilidade calculados separadamente pelo Método AHP e pela Técnica TOPSIS.

Embora as pontuações exatas sejam diferentes (devido às metodologias distintas), o fato de ambos os métodos identificarem um conjunto similar de indivíduos como os de "melhor performance"(os Top 10) reforça a consistência.



Figura 13 – Técnica de comparações

A comparação valida a robustez do modelo. A alta correlação entre as distribuições e a convergência na identificação dos Top Performers (melhores pontuações) AHP e TOPSIS demonstram que o Score de Confiabilidade final é independente da escolha do método e é uma métrica confiável para a tomada de decisão.



Figura 14 – Técnicas

5 Resultados Alcançados

O conjunto de análises e visualizações apresentadas (Figuras 1 a 13) confirma o sucesso da *sprint* na criação e validação de um **Score de Confiabilidade** e na segmentação estratégica da base de agricultores.

- **Determinação de k :** O Método do Cotovelo (Figuras 1 e 8) validou estatisticamente $k = 4$ como o número ótimo de *clusters*.
- **Visualização:** Os gráficos PCA (Figuras 2 e 3) demonstram a **eficácia do algoritmo de agrupamento** na criação de quatro segmentos distintos e bem separados.

O *Score* foi calculado e validado utilizando a **metodologia híbrida AHP e TOPSIS**. A comparação das distribuições (Figura 13) confirmou a **alta correlação** entre os resultados, garantindo que o *Score* de Confiabilidade é uma métrica estável, robusta e confiável para a gestão de Crédito Rural.

A maior parte da base se concentra nos *Scores* de Confiabilidade intermediários (2 e 3) (Figuras 5 e 7). Além disso, a base demonstra uma **alta diversificação de culturas** (Figura 6), indicando a necessidade de estratégias equilibradas de produto.

O modelo de *Score* validado e a segmentação de alta qualidade devem ser utilizados imediatamente para a criação de **políticas diferenciadas de Crédito Rural** e para a otimização das estratégias de relacionamento e gestão de risco em cada um dos quatro segmentos da base agrícola.

6 Conclusões

O projeto de análise demonstrou sucesso na modelagem e validação do Score de Confiabilidade e na segmentação da base de agricultores. Através do **Método do Cotovelo** (*Elbow Method*), o número ótimo de segmentos foi definido como $k = 4$, o que foi visualmente confirmado pelos gráficos de **Componentes Principais (PCA)** que mostram uma separação clara e coesa dos quatro *clusters*. A base de clientes se concentra majoritariamente nos *Scores* de Confiabilidade intermediários, com uma distribuição equilibrada de culturas, exigindo estratégias de gestão de risco e relacionamento balanceadas para o volume principal da carteira.

A pontuação foi assegurada pelo uso e comparação das técnicas de Análise Multicritério **AHP** e **TOPSIS**. A alta correlação e a similaridade nas distribuições dos *Scores* de ambos os métodos validam a métrica de Confiabilidade como estável e confiável. Desta forma, o projeto entrega uma ferramenta analítica robusta, transparente e alinhada com as prioridades do negócio agrícola. Recomenda-se a imediata adoção dos quatro **Scores de Confiabilidade** como a base para a criação de políticas diferenciadas na concessão de Crédito Rural, permitindo uma gestão de risco personalizada e a otimização da alocação de recursos em cada segmento.

Referências

- [1] Thomas L. Saaty. *The Analytic Hierarchy Process: Planning, Priority Setting, Resource Allocation*. McGraw-Hill International Book Company, New York, NY, 1980. Mencionado também em outras edições, como 1990 (RWS Publications).
- [2] Ching-Lai Hwang and Kwangsun Yoon. *Multiple Attribute Decision Making: Methods and Applications*, volume 186 of *Lecture Notes in Economics and Mathematical Systems*. Springer-Verlag, 1981.
- [3] J. B. MacQueen. Some methods for classification and analysis of multivariate observations. *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, 1:281–297, 1967.
- [4] Samuel Otiattakorah. *Agriculture Crop Yield: A Dataset for Crop Prediction*. 2023.
- [5] OpenAI. Gpt-4 technical report. Technical report, OpenAI, 2023. Referência para o uso de Large Language Models no aprimoramento de dados.
- [6] Google. Gemini: A family of highly capable multimodal models. Technical report, Google DeepMind, 2024. Referência para o uso de Large Language Models no aprimoramento de dados.
- [7] David L. Olson. *Data Quality: The Accuracy Dimension*. Morgan Kaufmann, San Francisco, CA, 2003. Obra seminal sobre qualidade de dados.
- [8] Wil M. P. van der Aalst. *Process Mining: Discovery, Conformance and Enhancement of Business Processes*. Springer, Berlin, 2011. Obra que aborda a engenharia de processos e dados para extração de conhecimento.
- [9] Omkar S. Vaidya and Satish Kumar. Analytic hierarchy process (ahp) application in water resources planning and management: A review. *European Journal of Operational Research*, 161(1):1–29, 2005.